Узнали, сколько получают в IT

lola_kochieva
7 сен 2022 в 03:12

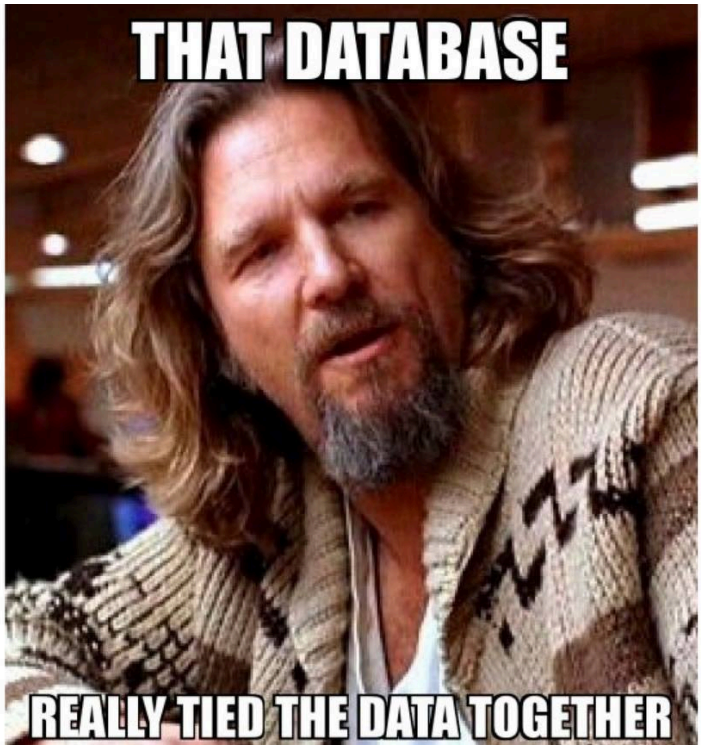
Введение в базы данных

7 мин 80K

SQL*, Big Data*, Терминология IT

Прежде чем начать рассказывать о базах данных, скажу, для кого эта статья. Если вы бывалый разработчик, то смело пропускайте статью, ничего нового вы с ней не найдете. Статья для тех, кто только планирует начать карьеру в дата-аналитике или data science, кто много раз слышал словосочетание «база данных», но не до конца понимает, что это.

Я решила написать эту статью, потому что именно такой статьи мне очень не хватало несколько лет назад, когда я только начала карьеру в аналитике данных. Тогда я часто слышала слова «база данных», «реляционная база», «primary key», примерно понимала, что они означают, но единую картину в голове у меня сложить не получалось.



Что такое база данных и зачем она?

Компании часто собирают информацию о своих клиентах, сотрудниках, операциях, финансах и т. д. Потом эту информацию можно выгодно использовать. Например, можно ее проанализировать и понять, какими способами можно увеличить прибыль. Можно на ее основе построить хитрые MLмодели, которые помогут улучшить продукт. Или, в конце концов, эту информацию можно просто перепродать другим компаниям.

Чтоб собирать и анализировать информацию, надо уметь ее сохранять. Конечно, можно сохранять информацию в печатном виде в обычных папках или в Excel-файлах. И многие компании до сих пор так сохраняют информацию. Однако, такое подойдет только для маленьких компаний с небольшим количеством данных. Когда компания вырастает, то и данных становится много, такие варианты сохранения информации становятся непригодны. Тогда на помощь приходят базы данных.

Базы данных помогают справиться с большим количеством проблем, решить которые папкам и Excel-файлам не под силу:

- В базе данных можно хранить очень огромное количество данных – миллиарды и триллионы записей;
- Базы помогают защищать данные - они позволяют давать доступ к данным только определенному кругу лиц. При этом можно ставить ограничения, кому к каким данным можно давать доступ и какого типа доступ, только чтение или редактирование тоже;
- Базы данных могут помогать следить за правильностью данных с помощью различного вида проверок;
- Также, базы данных могут позволять большому количеству людей одновременно взаимодействовать с данными.

Так что же такое база данных? Если говорить коротко, то это определенная структура, в которой хранится информация. Я понимаю, что из этого определения пока мало что понятно. Однако, более конкретное определение дать сложно, потому что существует много типов баз данных, и все они совершенно разные.

Я думаю, это определение станет понятнее, когда я далее опишу наиболее популярные типы баз данных на конкретных примерах.

Типы баз данных

Существует много разных типов баз данных. Наиболее популярные типы:

- Реляционные базы данных
- Key-value базы данных
- Документно-ориентированные базы данных
- Графовые базы данных
- Колоночные базы данных

Далее я расскажу о каждом из этих типов. Однако, начну я реляционных баз данных и больше всего буду рассказывать о них, потому что именно этим типом баз данных чаще всего пользуются аналитики данных и data scientist-ы.

Реляционные базы данных (MySQL, PostgreSQL, Oracle DB)

Реляционная база данных – это база данных, которая состоит из таблиц. У реляционной базы данных 2 очень важные характеристики:

- Данные распределены по смыслу по таблицам
- Между таблицами есть отношения

Рассмотрим пример реляционной базы. Допустим, у нас есть сервис доставки еды. Тогда, если мы построим реляционную базу данных для этого сервиса, то она, скорее всего, будет содержать следующие таблицы:

- Таблица с заказами
- Таблица с клиентами
- Таблица с курьерами

- Таблица с ресторанами

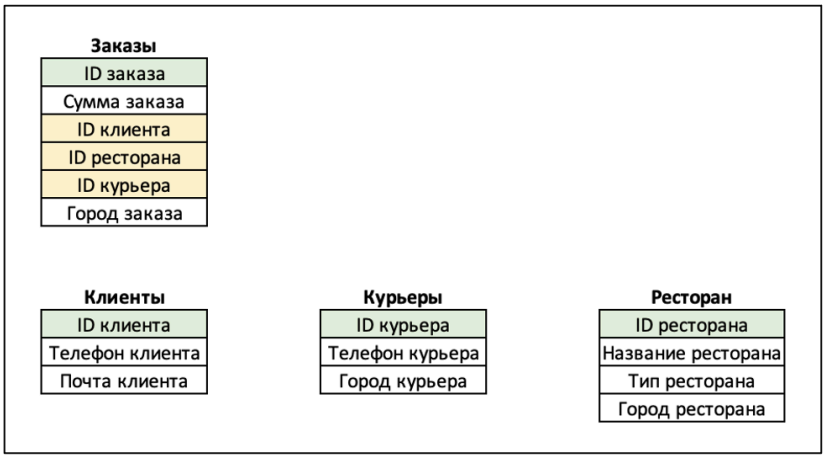


Рис 1. Пример реляционной базы данных

На рисунке 1 я попыталась изобразить графически реляционную базу данных. Мы видим таблицы, из которых состоит база, и также видим, какие столбцы содержит каждая из таблиц.

Как я отметила выше, второй важной характеристикой реляционных баз данных является то, что между таблицами существуют отношения. Отношения между таблицами определяются с помощью primary key и foreign key.

Primary key – это столбец (или группа столбцов) таблицы, который содержит уникальные значения для каждой строки. На примере выше primary key каждой таблицы я выделила зеленым цветом. То есть, например, в таблице с заказами каждая строка будет описывать отдельный заказ. Не будет 2 строк, которые описывают один и тот же заказ, потому ID заказа будет разный для каждой строки.

Foreign key – это столбец в таблице, который содержит primary key другой таблицы. На рисунке foreign key отмечены желтым. То есть, таблица с заказами содержит ID клиента, который является primary key в таблице с клиентами, но в таблице с заказами он будет foreign key.

Primary key и foreign key помогают не только связывать между собой таблицы реляционной базы данных отношениями. Они еще помогают следить за целостностью и правильностью данных в базе. Например, если мы ошибемся в ID клиента, добавляя новый заказ в таблицу с заказами, то база выдаст ошибку, так как не найдет соответствующий ID клиента в таблице с клиентами.

Для взаимодействия с реляционными базами данных чаще всего используется **SQL** (Structured QueryLanguage). Это специальный язык программирования, на котором пишутся запросы к реляционной базе. SQL-запросами можно создавать и удалять таблицы в реляционной базе, изменять данные в существующих таблицах и доставать из таблиц необходимую информацию.

Как я уже говорила выше, реляционные базы данных удобно использовать в аналитике, так как информация в них структурирована и распределена по смыслу, что, конечно, мечта любого аналитика. Однако, аналитики часто пишут сложные и не очень эффективные SQL-запросы, потому важно придумывать способы ускорения обработки запросов к реляционной базе.

Одним из наиболее популярных методов ускорения работы запросов к реляционным базам данных является **индексирование таблиц**. Индекс – это определенный столбец в таблице, по которому осуществляется поиск.

Приведу пример работы индекса. Например, мы хотим найти все заказы клиента 007 из ресторана 1. Тогда, если у нас в таблице с заказами нет индекса, то мы будем перебирать все заказы пока не найдем нужные. Если же у нас есть индекс в таблице с заказами, то ситуация будет иной. Допустим, что индексом является столбец ID ресторана. Тогда наши данные в таблице с заказами

будут сгруппированы по ID ресторана. И тогда при поиске заказов клиента 007 из ресторана 1, мы не будем перебирать всю таблицу с заказами, а найдем группу заказов из ресторана 1 и будем искать необходимые данные внутри этой группы.

Из примера выше с индексом выше понятно, что индексом удобно выбирать такой столбец, в разрезе которого часто ищутся данные.

Также, одним из важных свойств реляционных баз данных является **соответствие требованиям ACID**. Я не буду углубляться в детали этих требований, только отмечу, что эти требования гарантируют целостность и корректность данных, несмотря на ошибки, системные сбои, перебои в питании, изменение данных несколькими пользователями одновременно и прочие необычные ситуации.

Выглядит так, что реляционная база данных идеальная база, и непонятно, почему бы постоянно ее не использовать. Однако, у реляционной базы данных есть и недостатки, и потому данный тип не всегда подходит для нужд бизнеса. Например, реляционная база данных не подходит для данных без четкой структуры, потому что мы не сможем разложить эти данные в отдельные таблицы по смыслу. А данных без четкой структуры гораздо больше, чем данных с четкой структурой.

Какие еще есть типы баз данных?

Прочие типы баз данных, которые не реляционные, часто называются noSQL базы данных. Обсудим наиболее популярные типы нереляционных баз данных.

Key-value базы данных (пример - Redis)

Название говорит о том, какие данные удобно хранить в Key-value базе – в такой базе хранят данные, которые удобно представить в виде пары ключ-значение. Основное преимущество таких баз – это очень быстрый поиск значения по ключу. При этом значение может содержать какие угодно типы данных.

Такие базы данных удобно применять в проектах, где необходимо выдавать быстрый результат по ключу, например, для онлайн торгов или сделок.

Key	Value
1	"apple"
2	1
3	{name: "Ann", surname: "Smith"}
4	null
5	"cherry"

Рис 2. Пример key-value базы данных

Документно-ориентированные (пример - Mongo DB)

В документно-ориентированной базе данных единицей хранения является документ (который может быть в формате json, или xml, или в каком-нибудь еще формате). Удобство таких баз в том, что в них быстро и легко записывать любые типы данных, при этом эти данные не обязаны обладать четкой структурой. Минус таких баз в том, что данные в них неудобно анализировать.

В моей предыдущей компании такой тип баз данных служил базой для реляционных баз. То есть сначала все данные попадали и сохранялись в документно-ориентированной базе. Потом команда дата инженеров обрабатывала эти огромные полотна информации, структурировала и складывала в реляционную базу данных, которую уже могла использовать команда аналитиков и Data Science.

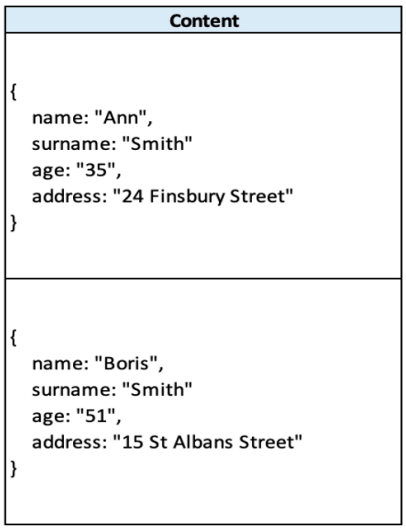


Рис 3. Пример документно-ориентированной базы данных

Графовые базы данных (пример - Orient DB)

Как следует из названия, в графовой базе данных данные хранятся в виде графов. Данный тип баз удобен, когда надо находить информацию не только о каком-то объекте, но и доставать информации о связях этого объекта с другими.

Например, в моей текущей компании данный тип баз используется для нахождения куки конкретного юзера и всех взаимосвязанных с этой кукой идентификаторов. Также, такой тип данных часто используется социальными сетями для сохранения информации не только о пользователях, но и о связях каждого пользователя с другими.

Колоночные (столбцовые) базы данных (примеры - Cassandra, Clickhouse)

В реляционных базах данных данные записаны в виде строк. Что же касается колоночных баз данных, то тут данные записываются в виде столбцов. Потому поиск данных в колоночной базе данных осуществляется не перебором всех строк, как это происходит в реляционной базе данных, а поиском необходимого значения в тех столбцах таблицы, которые нас интересуют.

Преимущество колоночных баз данных в том, что они могут быстро находить определенные значения в столбцах, которые нас интересуют.

Ну и напоследок

В заключение скажу, что типов баз данных великое множество. Какие-то типы приобретают популярность, какие-то больше не используются. У каждого типа свои преимущества и недостатки. И, выбирая тот или иной тип баз данных, надо исходить в первую очередь от вида вашего бизнеса и его потребностей.

Теги: база данных, реляционная база данных, sql, аналитика данных

Хабы: SQL, Big Data, Терминология IT

+7 209 21

Редакторский дайджест
Присылаем лучшие статьи раз в месяц
Электропочта

Подписаться

Оставляя почту, я принимаю Политику конфиденциальности и даю согласие на получение рассылок



29
Карма

@lola_kochieva
Пользователь

Подписаться

Комментарии 21

Публикации

ЛУЧШИЕ ЗА СУТКИ ПОХОЖИЕ



w5346c
15 часов назад

Как я пытался трудоустроиться в Яндекс в 2026

Простой 5 мин 19K

+137 48 82



alizar
19 часов назад

RAW — единственный оригинал фотографии. В��ё остальное постобработка

Простой 8 мин 14K

Обзор

+54 63 85



Ka1seR
20 часов назад

Как отчисление одного студента может закрыть всю кафедру. Нормализуем БД и избавляемся от аномалий

Простой 9 мин 8.6K

Туториал

+44 53 7



beget_com
21 час назад

Взлетай! Как и на чем передвигались пассажиры в дореактивную эру гражданской авиации. Часть 2

Средний 14 мин 12K

Обзор

+36 11 14

StraNNicK
14 часов назад

Основы системного администрирования Linux: от командной строки до веб-сервера

Простой 1 мин 8.1K

Туториал

+30 90 7

OpenClaw_Lab
16 часов назад

Мультиагентность в OpenClaw: отдельные агенты, субагенты и ACP (вайбкодим через тг)

Простой 4 мин 7.6K

Туториал

+28 34 2

interpres
15 часов назад

Ключ от всех дверей: как я взломал все электросамокаты одного производителя

Средний 12 мин 6.1K

Кейс Перевод

+26 10 2

RationalAnswer
23 часа назад

Курс рубля опять начал падать, а Nvidia умудрилась выбесить геймеров

7 мин 12K

Дайджест

+26 8 8

andreyyykovvv
22 часа назад

Метеостанция на Atmega328 и NRF24L01 с выносным датчиком

Средний 11 мин 8.4K

+24 42 9

turov
20 часов назад

Веб-графика, которая вредит: что разработчики делают не так

Простой 17 мин 7.5K

Туториал

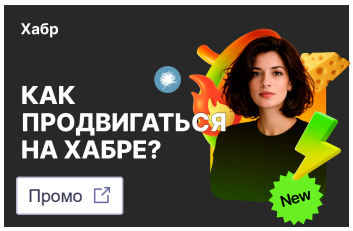
+22 17 4

Сезон Heavy Digital: истории о цифровых двойниках, машинном зрении и IIoT

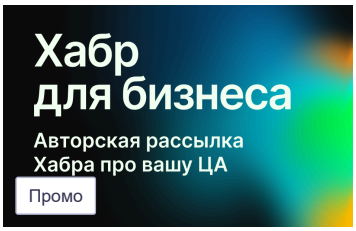
Турбо

Показать еще

МИНУТОЧКУ ВНИМАНИЯ



600 маркетологов уже в курсе



Подпишитесь на авторскую рассылку Хабра



Сканирование не поможет: управляем уязвимостями

ВАКАНСИИ

Разработчик программного обеспечения авионики
от 70 000 до 200 000 ₽ · Котлин-Новатор · Санкт-Петербург

Data Scientist
от 100 000 ₽ · Strikt · Можно удаленно

Системный аналитик
от 130 000 ₽ · Synapse AI · Москва · Можно удаленно

Data Engineer/Дата инженер (ученик)
от 90 000 до 100 000 ₽ · Aston · Москва · Можно удаленно

Бизнес-аналитик (предпроектные обследования / Process Consulting / AI)
от 250 000 до 350 000 ₽ · Ай-Титул · Москва

Больше вакансий на Хабр Карьере

ЧИТАЮТ СЕЙЧАС

Я закрыл магазины, поставил всё на Вайлдберриз и заработал долг 50 млн

51K 55

В Москве из-за ограничений мобильного интернета резко выросло использование публичного Wi-Fi

20K 7

К африканскому острову пристали суда с тысячами люксовых авто из-за кризиса в Ормузском проливе

80K 34

Хуанг заявил, что AGI достигнут — но построить NVIDIA ему не по плечу

7.9K 11

Геймеры создали сайт-насмешку над DLSS 5 с «бьютификацией» любой картинки

14K 41

Сезон Heavy Digital: истории о цифровых двойниках, машинном зрении и IIoT

Турбо

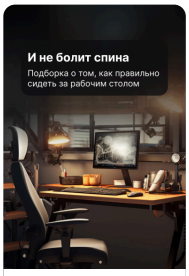
ИСТОРИИ



Пресс, который мы заслужили



Годнота из блогов компаний



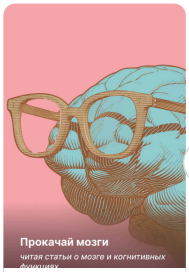
Ваша спина очень важна для вас



Просто скажи «th»



Работать и учиться с умом



Схватил за мозг

БЛИЖАЙШИЕ СОБЫТИЯ

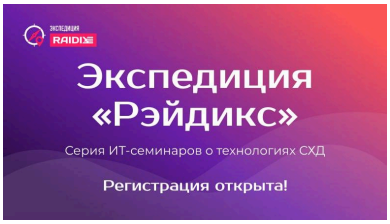


26 февраля – 31 марта

Авторская рассылка Хабра для бизнеса

Онлайн

Маркетинг

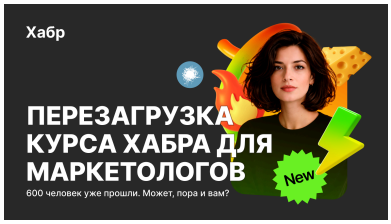


3 марта – 9 июня

Экспедиция «Рэйдикс»

Екатеринбург • Новосибирск • Краснодар • Минск • Калининград • Ростов-на-Дону

Разработка Другое

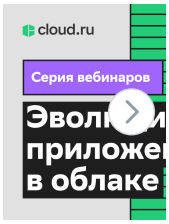


9 – 31 марта

Как не-ИТ бренду продвигаться на Хабре?

Онлайн

Маркетинг



19 марта – 28 ап

Серия веби «Эволюция в облаке»

Онлайн

Разработка

Больше событий в календаре

Больше событий в календаре

Больше событий в календаре

Больше событий

© 2006–2026, Habr